

MultaClara

Asistente de verificación de comparendos de tránsito en Colombia
Avance 2 — Flujo RAG completo, evaluación con Ragas y chat desplegado

Samuel Alejandro Monsalve Sarmiento · Carlos Alberto Franco Hernandez
Desarrollo con IA · Octavo semestre · Octubre de 2026

Aplicación desplegada	https://multaclara.streamlit.app/
Repositorio GitHub	https://github.com/samsRPA/proyecto_final_app_ia

1. Resumen y selección del corpus

MultaClara es un asistente conversacional que, a partir del relato de un conductor, evalúa si la causal y el procedimiento de un comparendo cumplen los requisitos formales y si existe una posible defensa legal. En el Avance 1 se diseñó el prompt (system prompt con delimitadores XML, few-shot y salida JSON validada con Pydantic). En este Avance 2 se reemplazó el conocimiento normativo escrito a mano por un **pipeline RAG** sobre la norma real, se evaluó con **Ragas** y se desplegó una interfaz de chat con historial y fuentes.

Corpus. Ley 769 de 2002 (Código Nacional de Tránsito), 172 artículos, en PDF. Es la norma base de tránsito en Colombia: define las infracciones, el procedimiento del comparendo, las multas, la reducción de sanciones, los recursos, la caducidad y la prescripción, que son exactamente los elementos que el asistente debe contrastar con lo que cuenta el usuario. El PDF incluye las modificaciones posteriores (Ley 1383/2010, Decreto 019/2012, Ley 1696/2013, entre otras). El sistema conserva el control del índice vectorial y al modelo solo se le envían los fragmentos recuperados para cada consulta, nunca el corpus completo (los textos sí se envían a la API de embeddings al indexar).

2. Flujo RAG implementado




Figura 1. Flujo RAG de extremo a extremo: indexación (arriba) y consulta (abajo).

2.1 Decisiones técnicas y justificación de parámetros

Etapas	Decisión	Justificación
Ingesta	pypdf; normalización Unicode NFKC; detección de ARTÍCULO/TÍTULO/CAPÍTULO tolerante a formatos del PDF	Las ligaduras tipográficas del PDF (la 'fi' guardada como un solo carácter) rompían la búsqueda; el PDF trae 'ARTÍCULO3º' pegado, lo que ocultaba los artículos 3 y 128. Tras corregirlo se detectan los 172 artículos.
Chunking: criterio	Por artículo; si excede el tamaño, subdivisión recursiva (párrafo → PARÁGRAFO → línea → ' ' → ' ' → palabra)	El artículo es la unidad natural de significado legal y de cita. Cortar a ciegas mezclaría artículos y rompería las citas.
Chunking: tamaño	1200 caracteres	Cabe un artículo corto completo (idea legal íntegra) y mantiene el vector específico. Longitud media real: 786.
Chunking: solape	200 caracteres (~17 %)	Si un corte cae a media idea, el final del chunk previo se repite. Rango habitual: 10–20 %.
Contexto del chunk	Encabezado '[Ley 769/2002, Art. N Título Capítulo]' antes de vectorizar	El vector 'sabe' a qué norma pertenece.

Etapas	Decisión	Justificación
Embeddings	gemini-embedding-001, 768 dimensiones; task_type RETRIEVAL_DOCUMENT / RETRIEVAL_QUERY	Buen desempeño multilingüe y misma API/clave que el LLM (despliegue simple). 768 dim. (Matryoshka) reduce espacio y latencia con pérdida mínima.
Base vectorial	ChromaDB persistente, espacio coseno, 315 chunks	Local, sin servidor, viaja con el repositorio y guarda metadatos para citar: documento, artículo, título, capítulo, parte. Verifica que el modelo de embeddings coincida con el del índice.
Recuperación	Similitud coseno, top_k = 5	Equilibrio entre cobertura (que esté el artículo correcto) y ruido/costo de tokens. Los seguimientos cortos reutilizan el mensaje previo para recuperar.
Generación	Gemini, temperatura 0.2, JSON con response_schema (VeredictoMulta); contexto recuperado en el bloque <contexto_normativo>	Se reutiliza el Avance 1. La política 2 pasó de 'no citar artículos' a 'citar solo artículos del contexto y solo para lo que respaldan'; el código valida que las citas estén entre los fragmentos recuperados.

3. Ejecución de consultas y análisis de las respuestas

La evaluación de la sección 4 corrió 20 preguntas por el RAG real. Estos son extractos representativos (texto tomado de eval/runs/cabecera_respuestas.json), con los artículos que el sistema recuperó.

Pregunta	Respuesta del RAG (extracto)	Artículos recuperados	Clasificación
¿Cuál es la velocidad máxima permitida en las vías urbanas?	En las vías urbanas las velocidades maximas y minimas para vehiculos de servicio publico o particular seran determinadas y debidamente señalizadas por la autoridad de Transito competente en el distrito o municipio respectivo, sin que en ningun caso pueda sobrepasar los cincuenta (50) kilometros por hora, mientras que en zonas...	106, 107, 95	consulta_general
¿Con cuánta multa se sanciona a quien no utiliza el cinturón de seguridad?	Según la Ley 769 de 2002, Art. 131 (Ley 769 de 2002, Art. 131), no utilizar el cinturón de seguridad por parte de los ocupantes del vehículo es sancionado con una multa equivalente a quince (15) salarios mínimos legales diarios vigentes (SMLDV).	131, 82	consulta_general
¿Cuál es la mejor forma de sobornar a un policía de tránsito para que no me ponga el comparendo?	No puedo ayudarte con sugerencias para sobornar a una autoridad, ya que promueve conductas ilegales. Mi proposito es brindarte orientacion legal sobre tus derechos y los procedimientos de transito validos.	135, 136, 159	fuera_de_alcance
¿Cuál es la multa por volar en escoba sobre la ciudad?	Mi proposito es ayudarte unicamente con comparendos o procedimientos de transito terrestres en Colombia. Las escobas voladoras escapan de la normatividad vial aplicable.	131, 58	fuera_de_alcance

Análisis

- **Velocidad (Art. 106).** Recupera el artículo exacto y responde con las cifras de la ley (50 km/h en vías urbanas; 30 km/h en zonas escolares y residenciales), citándolo.
- **Cinturón (Art. 131).** Antes de la mejora el asistente respondía que 'la base no precisa el monto'; después responde 15 SMLDV. Se analiza en la sección 4.3.
- **Soborno y escoba voladora.** Se clasifican como fuera de alcance: el asistente se niega a ayudar con sobornos y no inventa una infracción inexistente. No se muestran fuentes, porque serían irrelevantes.

- **Validación de citas.** En las 20 respuestas finales no hay artículos citados fuera del contexto recuperado (0 citas no respaldadas).

Capturas de consultas sobre el RAG

```
(.venv) PS C:\Users\cafh2\Documents\Universidad\Octavo Semestre\Desarrollo con IA\Tareas\proyecto_final_app_ia> python main.py --demo

=== Caso demo 1 ===
Tu: Me detuvieron por no llevar el cinturón de seguridad puesto. El agente estaba uniformado, se identifico, me explico la razon, y me dio la copia impresa del comparendo con todos los datos y su firma.

Clasificación: infraccion de transito
Resumen: El conductor fue detenido por no llevar el cinturón de seguridad; el agente siguió el procedimiento completo entregando copia del comparendo.
Causal reportada: No utilizar el cinturón de seguridad por parte de los ocupantes del vehículo.

Hallazgos:
- [cumple] Identificación del agente: El agente estaba uniformado y se identificó debidamente.
- [cumple] Entrega de copia del comparendo: Se entregó al conductor la copia impresa del comparendo con todos los datos y la firma del agente (Ley 769 de 2002, Art. 135).

Riesgo de nulidad: bajo
¿Tiene posible defensa?: No

Fundamento: Con base en los hechos narrados y la normatividad de tránsito, el agente cumplió con los requisitos formales mínimos de identificación y entrega de la orden de comparendo (Ley 769 de 2002, Art. 135).

Recomendaciones:
- Revisa los plazos establecidos en el comparendo para presentarte ante la autoridad de tránsito o realizar el pago con los descuentos aplicables.
- Si consideras que existió alguna circunstancia de fuerza mayor, asiste a la audiencia en los términos indicados para ejercer tu derecho de defensa.

---
Mult Clara ofrece una orientación informativa inicial y no reemplaza una asesoría jurídica formal. Verifica cualquier plazo o recurso con el organismo de tránsito competente o un abogado.

Fuentes recuperadas:
- Ley 769 de 2002, Art. 131 (similitud 0.69): (Encabezado del grupo: C. Será sancionado con multa equivalente a quince (15) salarios mínimos legales diarios...
- Ley 769 de 2002, Art. 131 (similitud 0.69): (Encabezado del grupo: C. Será sancionado con multa equivalente a quince (15) salarios mínimos legales diarios...
- Ley 769 de 2002, Art. 2 (similitud 0.69): Cinturón de seguridad: Conjunto de tiras, provisto de hebilla de cierre, dispositivos de ajuste y de unión, cu...
- Ley 769 de 2002, Art. 135 (similitud 0.68): La orden de comparendo deberá estar firmada por el conductor, siempre y cuando ello sea posible. Si el conduct...
- Ley 769 de 2002, Art. 135 (similitud 0.68): ARTÍCULO 135. PROCEDIMIENTO. Modificado por el art. 22, Ley 1383 de 2010. Ante la comisión de una contravención...
```

Figura 2. Consulta 1 ejecutada con python main.py --demo, con las fuentes recuperadas.

```
=== Caso demo 2 ===
Tu: Un agente sin uniforme ni carne visible me paro y me puso un comparendo por 'conduccion temeraria' sin explicarme en que consistia. No me dieron copia del comparendo en el momento ni me dijeron como reclamar.

Clasificación: infraccion de transito
Resumen: Un agente sin uniforme ni carné visible detuvo al usuario, impuso un comparendo por 'conducción temeraria' sin dar explicaciones ni copia física en el momento, y omitió informar sobre los mecanismos de reclamación.
Causal reportada: Conducción temeraria

Hallazgos:
- [no cumple] Identificación del agente: El usuario relata que el agente estaba sin uniforme ni carné visible.
- [no cumple] Entrega de copia del comparendo: No se le entregó copia de la orden de comparendo en el momento de la detención, a pesar de que la norma exige su entrega al conductor (Ley 769 de 2002, Art. 135).
- [no cumple] Notificación de derechos y plazos: El agente no explicó la causal ni indicó cómo o dónde reclamar o presentarse.

Riesgo de nulidad: alto
¿Tiene posible defensa?: Si

Fundamento: El procedimiento descrito presenta graves fallas en los requisitos formales mínimos exigidos por la ley, tales como la identificación de la autoridad, la entrega de la copia física del comparendo y la información sobre el derecho a la defensa (Ley 769 de 2002, Art. 135). Estas omisiones configuran un riesgo alto de nulidad.

Recomendaciones:
- Acércate al organismo de tránsito de tu localidad para verificar si el comparendo fue efectivamente registrado en el sistema.
- Solicita una copia formal del comparendo y de los informes o soportes que haya presentado el agente.
- Presenta tus descargos y solicita la revocatoria o nulidad del comparendo argumentando las fallas de procedimiento (omisión de entrega de copia y falta de identificación adecuada).

---
Mult Clara ofrece una orientación informativa inicial y no reemplaza una asesoría jurídica formal. Verifica cualquier plazo o recurso con el organismo de tránsito competente o un abogado.

Fuentes recuperadas:
- Ley 769 de 2002, Art. 135 (similitud 0.70): La orden de comparendo deberá estar firmada por el conductor, siempre y cuando ello sea posible. Si el conduct...
- Ley 769 de 2002, Art. 129 (similitud 0.70): ARTÍCULO 129. DE LOS INFORMES DE TRÁNSITO. Los informes de las autoridades de tránsito por las infracciones pr...
- Ley 769 de 2002, Art. 135 (similitud 0.70): ARTÍCULO 135. PROCEDIMIENTO. Modificado por el art. 22, Ley 1383 de 2010. Ante la comisión de una contravención...
- Ley 769 de 2002, Art. 137 (similitud 0.68): ARTÍCULO 137. INFORMACIÓN. En los casos en que la infracción fuere detectada por medios que permitan comprobar...
- Ley 769 de 2002, Art. 135 (similitud 0.68): PARÁGRAFO 1. La autoridad de tránsito entregará al funcionario competente o a la entidad que aquella encargue ...
```

Figura 3. Consulta 2 (procedimiento con defectos): hallazgos, riesgo de nulidad y fuentes.

4. Evaluación con Ragas

Dataset. 20 preguntas con respuesta de referencia (ground truth) escrita a partir del texto real de la ley (eval/dataset_eval.json): 16 dentro del corpus (cinturón, multas, procedimiento, firma, recursos, caducidad, prescripción, notificación, velocidad, inmovilización, embriaguez, casco, SOAT), 2 que parecen del dominio pero la base no cubre, y 2 fuera de alcance (soborno y escoba voladora). Como la salida del RAG es JSON, para Ragas se extrae la justificación en prosa (*fundamento* y explicaciones de los hallazgos, o *respuesta_fuera_de_alcance*). **Juez:** gemini-3.5-flash-lite. Las 4 métricas se promedian sobre las 16 preguntas del corpus; las de control se juzgan por su comportamiento de rechazo.

4.1 Resultados

Métrica	Baseline	Con encabezado de grupo	Diferencia
faithfulness (fidelidad al contexto)	0.956	0.984	+0.028
answer_relevancy (relevancia de la respuesta)	0.867	0.926	+0.059

Métrica	Baseline	Con encabezado de grupo	Diferencia
context_precision (precisión del contexto)	0.908	0.960	+0.052
context_recall (cobertura del contexto)	1.000	1.000	+0.000
hit_articulo (artículo esperado en el top-k; sin LLM)	1.000	1.000	+0.000
rechazo_correcto (4 preguntas de control)	1.00	0.75	-0.25




Figura 4. Métricas Ragas antes y después de la iteración de mejora.

4.2 Análisis: qué salió más bajo y a qué componente se atribuye

En el baseline, la métrica más baja fue **answer_relevancy (0.867)**, seguida de **context_precision (0.908)**. Al revisar los puntajes por pregunta, casi todo el hueco venía de una sola: la pregunta 2 (*¿con cuánta multa se sanciona no usar el cinturón?*), con fidelidad 0.5, relevancia 0.0 y precisión 0.0. El modelo respondió que 'la base no precisa el monto', aunque el Art. 131 sí lo dice (15 SMLDV).

Diagnóstico: chunking. El Art. 131 mide unos 28 000 caracteres y quedó dividido en 29 chunks. El encabezado de su grupo ('C. Será sancionado con multa equivalente a quince (15) SMLDV...') quedaba lejos de sus ítems: el fragmento con 'C.6. No utilizar el cinturón...' no traía la multa, y el fragmento con 'quince (15)' no traía C.6. El modelo recibió ambos, pero no pudo vincularlos y prefirió no inventar, por eso la fidelidad no cayó a 0. Es un fallo de **chunking** que se manifiesta en la **generación**. Nótese que *context_recall* y *hit_articulo* valían 1.0 y **no lo detectaron**: el fragmento correcto sí se recuperaba. Solo se vio leyendo las respuestas.

4.3 Iteración de mejora y resultado

Cambio aplicado: repetir en cada chunk del Art. 131 el encabezado de su grupo de multa (parámetro RAG_CABECERA_GRUPOS; en 0 reproduce el baseline). Se reindexó en una colección nueva y se volvió a evaluar con el mismo dataset y el mismo juez.

Resultado: la pregunta 2 ahora responde 'quince (15) SMLDV (Art. 131)'. Suben *faithfulness* (+0.028), *answer_relevancy* (+0.059) y *context_precision* (+0.052). **Interpretación honesta:** la mejora proviene de ese único caso; las otras 15 preguntas quedan prácticamente iguales, y las diferencias de ± 0.1 en otras son ruido (modelo y juez no deterministas; $n = 16$). Es un arreglo dirigido a la estructura de ese artículo, no una mejora general.

Sobre la baja de rechazo_correcto (1.00 → 0.75). La pregunta 17 ('conducción temeraria') se planteó como ausente de la ley, pero el Art. 131, grupo D, ítem D.7, sanciona 'conducir realizando maniobras altamente

peligrosas e irresponsables que pongan en peligro a las personas o las cosas' (30 SMLDV). Con el encabezado repetido, el modelo ahora lo encuentra y responde con fidelidad 1.0 y sin citas inventadas. **No es una alucinación: es un ítem mal planteado del dataset.** Se reporta tal cual y no se modificó el dataset después de ver los resultados.

4.4 Mejoras futuras

- Sustituir la pregunta 17 por un tema realmente ausente de la ley.
- Reranking y búsqueda híbrida (BM25 + vectores), útil para citas por número de artículo.
- Filtrar o marcar artículos derogados (p. ej. el Art. 128, inexecutable, sigue indexado).
- Repetir cada evaluación varias veces y promediar; ampliar el dataset.
- Incorporar normas faltantes (resoluciones, Ley 1843 sobre fotomultas).

5. Interfaz de chat desplegada

La interfaz está construida con **Streamlit** y desplegada en Streamlit Community Cloud: <https://multaclarastreamlit.app/>. Las credenciales se gestionan como *secrets* de la plataforma; nunca se incluyen en el repositorio.

- **Conversación real:** el historial se conserva en *st.session_state* y se reenvía al LLM, de modo que las preguntas de seguimiento entienden los turnos anteriores. La interfaz lo hace visible con un contador lateral ('Recuerdo N mensajes', tope de 6) y un aviso bajo cada respuesta de seguimiento ('Seguimiento: esta respuesta tiene en cuenta N mensajes anteriores').
- **Fuentes:** bajo cada respuesta se muestran documento, artículo, ubicación (título y capítulo), similitud y el fragmento recuperado. Son los fragmentos que realmente recibió el modelo.
- **Fuera de alcance:** se indica sin inventar y sin mostrar fuentes irrelevantes; si el modelo cita un artículo que no estaba en el contexto, la interfaz lo advierte.
- **Protección de cuota:** los mensajes se limitan a 1500 caracteres.




Figura 5. Pantalla inicial de la aplicación desplegada.




Figura 6. Primera pregunta de la conversación y la respuesta del asistente.




Figura 7. Pregunta de seguimiento en la misma conversación: la respuesta depende del turno anterior.




Figura 8. Panel 'Fuentes consultadas' desplegado, con artículo y fragmento.




Figura 9. Caso fuera del alcance del corpus: el asistente lo rechaza sin inventar.

6. Limitaciones

- El corpus es solo la Ley 769 de 2002; no incluye resoluciones, la Ley 1843 (fotomultas) ni jurisprudencia, y puede haber texto derogado indexado.
- Es un LLM: aun con buen contexto puede razonar mal. La salida es orientación informativa y no reemplaza la asesoría de un abogado.
- Evaluación pequeña (16 preguntas del corpus + 4 de control) con un LLM juez no determinista; *context_recall* satura en 1.0 y no discrimina.
- La cuota gratuita de la API es compartida por todos los visitantes de la aplicación pública.

7. Enlaces

Aplicación: <https://multaclaras.streamlit.app/>

Repositorio: https://github.com/samsRPA/proyecto_final_app_ia

Anexo A. Puntajes de Ragas por pregunta

F = faithfulness, R = answer_relevancy, P = context_precision, Rc = context_recall. Las preguntas de control (17–20) se interpretan por su comportamiento de rechazo, no por estas métricas.

#	Tipo	Pregunta	Baseline (F / R / P / Rc)	Con encabezado (F / R / P / Rc)
1	dentro corpus	¿Es obligatorio el uso del cinturón de...	1.00 / 0.90 / 1.00 / 1.00	1.00 / 0.88 / 0.83 / 1.00
2	dentro corpus	¿Con cuánta multa se sanciona a quien no...	0.50 / 0.00 / 0.00 / 1.00	1.00 / 0.91 / 1.00 / 1.00
3	dentro corpus	¿Pueden viajar niños en el asiento delantero...	1.00 / 0.95 / 1.00 / 1.00	1.00 / 0.95 / 1.00 / 1.00
4	dentro corpus	¿Cuál es el procedimiento que debe seguir la...	1.00 / 0.90 / 1.00 / 1.00	1.00 / 0.93 / 1.00 / 1.00
5	dentro corpus	¿Qué pasa si el conductor no se presenta...	0.80 / 0.92 / 1.00 / 1.00	1.00 / 0.92 / 1.00 / 1.00
6	dentro corpus	¿Debe el conductor firmar el comparendo? ¿Qué...	1.00 / 0.93 / 1.00 / 1.00	1.00 / 0.96 / 1.00 / 1.00
7	dentro corpus	¿Qué ocurre si la persona rechaza la comisión...	1.00 / 0.87 / 0.83 / 1.00	1.00 / 0.86 / 0.83 / 1.00
8	dentro corpus	¿Qué recursos se pueden presentar contra las...	1.00 / 0.85 / 1.00 / 1.00	1.00 / 0.88 / 1.00 / 1.00
9	dentro corpus	¿En cuánto tiempo caduca la acción por una...	1.00 / 0.98 / 1.00 / 1.00	1.00 / 0.98 / 1.00 / 1.00
10	dentro corpus	¿En cuánto tiempo prescriben las sanciones...	1.00 / 0.96 / 1.00 / 1.00	1.00 / 0.99 / 1.00 / 1.00
11	dentro corpus	¿Cómo se notifican las providencias que se...	1.00 / 0.94 / 1.00 / 1.00	1.00 / 0.94 / 1.00 / 1.00
12	dentro corpus	¿Cuál es la velocidad máxima permitida en las...	1.00 / 0.94 / 1.00 / 1.00	1.00 / 0.94 / 1.00 / 1.00
13	dentro corpus	¿En qué consiste la inmovilización de un...	1.00 / 1.00 / 1.00 / 1.00	1.00 / 0.97 / 1.00 / 1.00
14	dentro corpus	¿Qué sanción se impone, además de la multa, a...	1.00 / 0.92 / 1.00 / 1.00	1.00 / 0.89 / 1.00 / 1.00
15	dentro corpus	¿Qué obligaciones tienen los motociclistas...	1.00 / 0.88 / 1.00 / 1.00	0.75 / 0.92 / 1.00 / 1.00
16	dentro corpus	¿Qué seguro necesita un vehículo para poder...	1.00 / 0.93 / 0.70 / 1.00	1.00 / 0.89 / 0.70 / 1.00
17	sin respuesta corpus	¿Cuántos salarios mínimos de multa...	0.50 / 0.00 / 0.48 / 0.50	1.00 / 0.84 / 1.00 / 0.00
18	sin respuesta corpus	¿Cuánto es en pesos colombianos la multa de...	1.00 / 0.00 / 1.00 / 1.00	0.60 / 0.00 / 0.68 / 1.00
19	fuera alcance	¿Cuál es la mejor forma de sobornar a un...	0.00 / 0.00 / 0.00 / 0.00	0.00 / 0.85 / 0.00 / 0.00
20	fuera alcance	¿Cuál es la multa por volar en escoba sobre...	0.00 / 0.78 / 0.64 / 0.00	0.00 / 0.85 / 1.00 / 1.00